

Analisis del Efecto de la tasa politica monetaria en la Economia de Honduras basandose en la tasas de interes del sector finaciero

Nelson Molina

Septiembre 2022

Contents

| | | |
|----------|--|-----------|
| 1 | Introduction | 3 |
| 1.1 | Objetivo general | 3 |
| 1.2 | Objetivo Especifico | 3 |
| 1.3 | Preguntas de investigación | 3 |
| 2 | Definiciones y Notación | 4 |
| 2.1 | El Modelo Vector Autorregresivo (VAR) | 4 |
| 2.2 | Como funciona un modelo VAR | 4 |
| 2.3 | Tasa de interes y sus clasificación | 4 |
| 2.4 | Indice de precio al consumidor | 5 |
| 2.5 | Tasa Politica Monetaria (TPM) | 5 |
| 3 | Series de Tiemo | 5 |
| 3.1 | Aplicaciones de las series de tiempo | 5 |
| 3.2 | Componentes de la serie de tiempo | 6 |
| 3.3 | Tendencia secular: | 6 |
| 3.4 | Variación estacional | 6 |
| 3.5 | Ejemplo de series. | 7 |
| 3.6 | Variación cíclica: | 9 |
| 3.7 | Variación Irregular: | 9 |
| 4 | b.Tendencia de una serie. | 9 |
| 4.1 | Tendencia lineal | 9 |
| 4.2 | Tendencia no lineal | 9 |
| 5 | Analisis de una serie de tiempo | 9 |
| 5.1 | Test de causalidad de Wiener-Granger | 10 |
| 5.2 | Resultados Preliminares | 10 |
| 5.3 | Especificacion del Modelo | 10 |
| 5.4 | Contraste Dickey-Fuller | 10 |
| 5.5 | Contraste Dickey-Fuller Aumentada(ADF) | 11 |
| 5.6 | Determinacion del número máximo de retardos: | 12 |
| 6 | Estimacion consistente del modelos | 13 |
| 6.1 | Autocorrelación | 14 |

| | | |
|-----------|--|-----------|
| 7 | Chequeo del modelo | 15 |
| 7.1 | Condicion de Estabilidad | 15 |
| 7.2 | Prueba de Autocorrelacion Serial en los Residuales: | 15 |
| 7.3 | Prueba de Normalidad de los Residuales: | 15 |
| 7.4 | Prueba de Homocedasticidad de la Varianza de los Residuales: | 16 |
| 8 | Contraste de la Causalidad de Granger: | 16 |
| 8.1 | Funciones Impulso-Respuesta: | 17 |
| 8.2 | Analisis e Interpretación de las graficas. | 17 |
| 9 | Conclusiones y Recomendaciones | 22 |
| 10 | Bibliografia | 22 |

1 Introduction

En este trabajo se creara un modelo econométrico de vectores autorregresivos para el estudio o análisis fundamental de los bancos centrales incluyendo al Banco Central de Honduras es el control de la inflación, y la Política Monetaria tiene como objetivo dicho fin, dicha política influye en las tasas de interés del sector financiero, las cuales son transmitidas a la economía, a través de préstamos que las personas o las empresas solicitan al sector financiero, en el caso de Honduras no se tiene un modelo que ayude a medir el efecto que causa en las tasas de interés del ámbito financiero dado esto se buscará un modelo econométrico basado en la serie de tiempo y vectores autoregresivos, para poder identificar al buen efecto bien negativo o positivo que le causa la tasa política monetaria a la economía hondureña esto basándose en cuatro variables que se encuentran en base de datos del banco central de Honduras esta es la tasa de interés pasiva y activa y utilizando los precios del consumidor llamados IPC Y también utilizando la tasa política monetaria.

Para realizar esta investigación, en este trabajo se propondrá un modelo de vectores autorregresivos (VAR), para la Tasa de Política Monetaria, Tasas de Interés Pasivas y Activas (TIP y TIA) el Índice de Precios al Consumidor (IPC) utilizando datos de mensuales en promedios ponderados para TIP y TIA para el periodo 05/2005-08/2021, correspondientes a Honduras.

Los modelos VAR son métodos econométricos válidos para llevar a cabo análisis empírico y permiten separar los efectos de distintos impulsos sobre las variables objeto de estudio. Estos modelos han gozado de una gran popularidad entre los macroeconomistas y son utilizados por los Bancos Centrales para la realización de predicciones macroeconómicas que sirvan de apoyo en la toma de decisiones futuras.

1.1 Objetivo general

El objetivo de este trabajo es medir el efecto de la tasa de Política Monetaria la cual es ejecutada por el Banco Central de Honduras, sobre las tasas de interés del sector financiero en sector económico de Honduras.

Para lograr este objetivo, se utilizan los modelos de Vectores Autoregresivos (VAR), con datos mensuales correspondientes de Mayo de 2005 - Agosto de 2021 de Tasa de interés Activas y Pasivas, Tasa de Política Monetaria e Índice de Precios al Consumidor. Las pruebas de causalidad de Granger indican que la tasa de Política Monetaria del BCH, si causa en el sentido de Granger a las tasas de interés Pasivas y Activas. Sin embargo, la tasa de Política Monetaria no causa en sentido de Granger al IPC. Además, las funciones impulso respuesta muestran evidencia de que un impulso en la TPM conduce a un aumento de las tasas de interés.

1.2 Objetivo Especifico

El objetivo específico es conocer el efecto de la Política Monetaria en la economía y buscar alternativa para mantener una Tasa de Inflación baja y estable, para no afectar el crecimiento económico alrededor del ámbito financiero del comercio de Honduras.

1.3 Preguntas de investigación

Que variables influyen o afectan el cambio de la tasa de interés del sector financiero?

Como afecta la tasa de Política Monetaria a la tasa de interés del sector financiero?

Que propuesta o solución se puede proponer para la regulación o el manejo de la tasa política monetaria para que no afecte la economía de Honduras de manera directa?

Que modelo explica el efecto de la tasa de Política Monetaria en la tasa de interés del sector financiero?

Observación: Utilizaremos los modelos de vectores autorregresivos VAR y series de tiempo para realizar el modelo con datos del BCH.

2 Definiciones y Notación

2.1 El Modelo Vector Autorregresivo (VAR)

El Modelo Vector Autorregresivo (VAR) es un conjunto de k regresiones temporales con k variables y p k variables independientes rezagadas. Los modelos VAR fueron originalmente propuestos por Sims (1980), como alternativa metodológica a la modelización econométrica convencional. Según Sims los modelos macroeconómicos tradicionales incorporaban restricciones de exclusión poco realistas. En los modelos VAR no se impone a priori ninguna restricción sobre la forma estructural. Por lo que no se cometen los potenciales errores de especificación que dicha restricción pudiera causar al ejercicio empírico. Esta nueva modelización permite especificar modelos que reflejen lo más fielmente posible las regularidades empíricas e interacciones entre las variables que se estudian.

2.2 Como funciona un modelo VAR

- Son modelos econométricos multivariados.
- Es una extensión de los modelos Autorregresivos Univariados. \item
- No hay variables endógenas o exógenas.
- Son un sistema de regresiones. caso más sencillo de un VAR es el bivariado. Se utilizan para pronósticos similar a otros modelos econométricos.
- VAR(p), donde p es el orden del modelo

Los modelos multivariantes de series temporales son una generalización de los modelos univariantes (manejan información contenida en la muestra). La diferencia es que en vez de una sola variable, hay n variables: En principio se van a especificar y estimar sobre variables estacionarias. Todos los modelos invertibles se pueden expresar en términos de un proceso autorregresivo. VAR(p) El presente de una variable dependerá de su pasado y del presente (a través de las innovaciones) y pasado de otras variables. En el modelo multivariante se tienen n ecuaciones y en cada una de ellas entran estructuras dinámicas sobre cada variable, con lo que la estructura dinámica del modelo es una matriz de $n \times n$ elementos

2.3 Tasa de interés y sus clasificación

En términos sencillos se define tasa de interés como: el índice manejado en la economía y finanzas para registrar la rentabilidad de un ahorro o el costo de un crédito, éste tiene una directa relación entre dinero y tiempo. En el caso que una persona decida invertir su dinero en un fondo bancario, o bien, que se le suma al costo final de una persona o entidad que resuelve obtener un préstamo o crédito.

- **Tasa de interés activa** Precio que cobra una persona o institución crediticia por el dinero que presta
- **Tasa de interés fija** Tasa de interés que se aplica durante el periodo de repago de un préstamo, cuyo valor se fija al momento de la concertación del crédito
- **Tasa de interés flotante** Es aquella que se paga durante la vida de un préstamo y varía en función de una tasa de interés de referencia

- **Tasa de interés pasiva** Precio que una institución crediticia tiene que pagar por el dinero que recibe en calidad de préstamo o depósito
- **Tasa de interés al rebatir** Tasa de interés que se aplica sobre el saldo adeudado.

2.4 Índice de precio al consumidor

El índice de precios al consumo (IPC) es un indicador que mide la variación de los precios de una cesta de bienes y servicios en un lugar concreto durante un determinado periodo de tiempo.

Este índice se utiliza para medir el impacto de las variaciones en los precios en el aumento de coste de vida. Para ello selecciona productos concretos, que se asemejan al consumo de una familia, como pueden ser determinados comestibles, calzado y textil, carburantes, transportes y otros servicios. Una vez recopilada la información realiza un seguimiento de sus precios durante un tiempo delimitado y concreto, que suele ser trimestral y anual.

2.5 Tasa Política Monetaria (TPM)

La Tasa de Política Monetaria es la tasa que establece el Banco Central como objetivo y referencia para las operaciones interbancarias, es decir, para los préstamos entre bancos, lo que a su vez influye en el comportamiento de las tasas que los bancos aplican a sus productos de cartera.

2. Cómo funciona: sube o baja

Podemos decir que la TPM es el semáforo de la política monetaria del país. Si sube es que el Banco Central trata de contraer la inflación, impactando en el poder adquisitivo de los agentes del mercado (personas y empresas), al afectar en alguna manera la demanda agregada interna. Si, por el contrario, baja, se busca expandir la economía facilitando dinero al costo más barato. En base a este instrumento es que el Banco Central trata de dar señales para el cumplimiento de sus metas de inflación.

3. Localmente que le influye

La Tasa de Política Monetaria va a estar influenciada directamente por la inflación (subida de los precios de los bienes y servicios) que haya en el país y la actividad económica. Todo está interrelacionado; si el aumento de la demanda no viene con una contraprestación por el lado de la oferta, se produce un desbalance, teniendo un impacto en la inflación y, por ende, en los salarios y en el poder adquisitivo. Al subir la TPM se busca reducir la presión y llevar a un equilibrio entre la oferta y la demanda.

4. Política Monetaria

Es la disciplina de la política económica que controla los factores monetarios para garantizar la estabilidad de precios y el crecimiento económico.

3 Series de Tiempo

Por serie de tiempo nos referimos a datos estadísticos que se recopilan, observan o registran en intervalos de tiempo regulares (diario, semanal, semestral, anual, entre otros). El término serie de tiempo se aplica por ejemplo a datos registrados en forma periódica que muestran, por ejemplo, las ventas anuales totales de almacenes, el valor trimestral total de contratos de construcción otorgados, el valor trimestral del PIB.

3.1 Aplicaciones de las series de tiempo

Hoy en día diversas organizaciones requieren conocer el comportamiento futuro de ciertos fenómenos con el fin de planificar, prevenir es decir para predecir lo que ocurrirá con una variable en el futuro a partir del comportamiento de esa variable en el pasado. En las organizaciones es de mucha utilidad en predicciones

a corto y mediano plazo, por ejemplo ver que ocurriría con la demanda de un cierto producto, las ventas a futuro, decisiones sobre inventario, insumos.

Economía: Precios de un artículo, tasas de desempleo, tasa de inflación, Índice de precios, precio del dólar, precio del cobre, precios de acciones, ingreso nacional bruto, etc. Meteorología: Cantidad de agua caída, temperatura máxima diaria, Velocidad del viento (energía eólica), energía solar, etc. Geofísica: Series sísmológicas.

Química: Viscosidad de un proceso, temperatura de un proceso.

Demografía: Tasas de natalidad, tasas de mortalidad.

Medicina: Electrocardiograma, electroencefalograma.

Marketing: Series de demanda, gastos, utilidades, ventas, ofertas.

Telecomunicaciones: Análisis de señales.

Transporte: Series de tráfico.

3.2 Componentes de la serie de tiempo

3.3 Tendencia secular:

La tendencia secular o tendencia a largo plazo de una serie es por lo común el resultado de factores a largo plazo. En términos intuitivos, la tendencia de una serie de tiempo caracteriza el patrón gradual y consistente de las variaciones de la propia serie, que se consideran consecuencias de fuerzas persistentes que afectan el crecimiento o la reducción de la misma, tales como: cambios en la población, en las características demográficas de la misma, cambios en los ingresos, en la salud, en el nivel de educación y tecnología.

3.4 Variación estacional

Variación estacional: El componente de la serie de tiempo que representa la variabilidad en los datos debida a influencias de las estaciones, se llama componente estacional. Esta variación corresponde a los movimientos de la serie que recurren año tras año en los mismos meses (o en los mismos trimestres) del año poco más o menos con la misma intensidad. Por ejemplo: Un fabricante de albercas inflables espera poca actividad de ventas durante los meses de otoño e invierno y tiene ventas máximas en los de primavera y verano, mientras que los fabricantes de equipo para la nieve y ropa de abrigo esperan un comportamiento anual opuesto al del fabricante de albercas.

¿Por qué es importante saber si las series de tiempo son estacionarias?

Una serie estacionaria es mucho más fácil de predecir. Si se comportaba de una manera en el pasado (digamos con una determinada media y varianza), podremos suponer que se seguirá comportando de la misma forma en el futuro. Bueno, o que tiene una gran probabilidad de continuar comportándose de la misma forma.

La mayoría de modelos que describen e intentan predecir el comportamiento de las series temporales funcionan bajo el supuesto de que la serie es estacionaria.

Además las teorías que se basan en series estacionarias son más fáciles de implementar.

¿Qué ocurre cuando tratamos series no estacionarias como si lo fueran?

El principal problema está en la estimación del riesgo.

Estaremos subestimando el riesgo, porque la distribución tiene colas más largas.

Estaremos sobrestimando los beneficios.

El margen de error de las previsiones es mayor.

3.5 Ejemplo de series.

Análisis de series temporales Lo primero que podemos hacer es un análisis visual.



Figure 1: Mi Figura

En este ejemplo, estamos con gráfico mensual del SP500 de los últimos 30 años. Tal y como pensábamos, los precios de cierre no son una serie estacionaria (a simple vista podemos ver que ni la media ni la varianza son constantes).

Estas son algunas transformaciones simples que podemos aplicar a nuestra serie temporal:

Transformación logarítmica La transformación logarítmica hace que la dispersión sea más o menos constante.




Figure 2: Mi Figura

Si analizamos el gráfico podemos ver que la transformación logarítmica sí que ha estabilizado un poco la dispersión. Sin embargo, no ha logrado que la media de la serie sea constante (se sigue apreciando una tendencia creciente).

Tendencia.

Una transformación que elimina la tendencia (buscamos estacionariedad en la media) es la diferenciación. La diferenciación nos permite eliminar la tendencia lineal a través de las diferencias regulares. Consiste simplemente en calcular la diferencia entre cada dato (en este caso mensual) y el anterior.




Figure 3: Mi Figura

Otra forma de trabajar para estabilizar la varianza es tomando la diferencia entre los logaritmos naturales de los precios (más sobre por qué trabajar utilizando logaritmos en este otro artículo)




Figure 4: Mi Figura

3.6 Variación cíclica:

Variación cíclica: Con frecuencia las series de tiempo presentan secuencias alternas de puntos abajo y arriba de la línea de tendencia que duran más de un año, esta variación se mantiene después de que se han eliminado las variaciones o tendencias estacional e irregular. Un ejemplo de este tipo de variación son los ciclos comerciales cuyos períodos recurrentes dependen de la prosperidad, recesión, depresión y recuperación, las cuales no dependen de factores como el clima o las costumbres sociales.

3.7 Variación Irregular:

Variación Irregular: Esta se debe a factores a corto plazo, imprevisibles y no recurrentes que afectan a la serie de tiempo. Como este componente explica la variabilidad aleatoria de la serie, es impredecible, es decir, no se puede esperar predecir su impacto sobre la serie de tiempo. Existen dos tipos de variación irregular:

a) Las variaciones que son provocadas por acontecimientos especiales, fácilmente identificables, como las elecciones, inundaciones, huelgas, terremotos.

b) Variaciones aleatorias o por casualidad, cuyas causas no se pueden señalar en forma exacta, pero que tienden a equilibrarse a la larga.

4 b.Tendencia de una serie.

4.1 Tendencia lineal

Tendencia lineal Como se dijo antes, la tendencia de una serie viene dada por el movimiento general a largo plazo de la serie. La tendencia a largo plazo de muchas series de negocios (industriales y comerciales), como ventas, exportaciones y producción, con frecuencia se aproxima a una línea recta. Esta línea de tendencia muestra que algo aumenta o disminuye a un ritmo constante. El método que se utiliza para obtener la línea recta de mejor ajuste es el Método de Mínimos Cuadrados.

4.2 Tendencia no lineal

Tendencia no lineal Cuando la serie de tiempo presenta un comportamiento curvilíneo se dice que este comportamiento es no lineal. Dentro de las tendencias no lineales que pueden presentarse en una serie se encuentran, la polinomial, logarítmica, exponencial y potencial, entre otras.

5 Analisis de una serie de tiempo

Es el procedimiento por el cual se identifican y aislan los factores relacionados con el tiempo que influyen en los valores observados. Una vez identificados, estos factores contribuirán en la interpretación de valores históricos y a pronosticar valores futuros. La forma más usual de representar una serie de tiempo es en función de las componentes tendencia y estacionalidad, es decir, mediante la ecuación.

$$X_t = T_t + E_t + \epsilon_t$$

Las variables se definen de la siguiente manera.

X_t = el valor de la serie temporal en el periodo t

T_t = componente de tendencia en el periodo t

E_t = es una funcion que representa la componente estacional

ϵ_t = el termino del error en el periodo t.

5.1 Test de causalidad de Wiener-Granger

El test de causalidad de Wiener-Granger, o causalidad de Granger, es una prueba estadística empleada para determinar si una serie temporal puede predecir a otra. Para ello se basa en la idea de que si una serie temporal X causa otra Y, los modelos de Y en los que se emplean datos retrasados de X e Y deben funcionar mejor los basados únicamente en datos retrasados de Y. Permitiendo identificar en series temporales en las que se observa una correlación que variable antecede a la otra.

El test solamente identifica si una variable antecede a otra en una serie temporal. Lo que la convierte en una buena predictora para la serie temporal. Es decir, si en unos datos se observa causalidad de Granger, no existe necesariamente un vínculo causal en el verdadero sentido de la palabra

5.2 Resultados Preliminares

Para llevar acabo este proyecto de investigacion se ha considerado la base de datos BancoCH.csv la cual contiene datos mensuales de; Tasas de Interes (Activas y Pasivas), Indice de Precios al Consumidor, Tasa de Política Monetaria y Tasa de Cambio de Mayo de 2005 a Agosto de 2021 que fueron extraídos de [http : //www.secmca.org/temp](http://www.secmca.org/temp)

Para esta investigación consideraremos solamente las primeras cuatro variables esto debido a que al realizar las pruebas de causalidad de Granger la Tasa de Cambio no tenia causalidad en ninguna variable. Lo que haremos sera determinar el Efecto de la Tasa de Política Monetaria en las Tasa de Interes del Sistema Financiero utilizando modelo de Vectores Autorregresivos (VAR).

En la figura 1 se puede observar cómo se comportan las series atraves del tiempo, se observa cómo la variable IPC que hace referencia al índice de precios al consumidor tiene un comportamiento ascendente.

5.3 Especificacion del Modelo

Como las variables que hemos considerado son Tasa de Interes Activa (A), Tasa de Interes Pasiva (P), Tasa de Política monetaria (M) Indice de Precios al Consumidor (I), proponemos el siguiente modelo:

$$\begin{pmatrix} A_t \\ p_t \\ M_t \\ I_t \end{pmatrix} = \begin{pmatrix} \delta_1 \\ \delta_1 \\ \delta_3 \\ \delta_4 \end{pmatrix} + C^1 \begin{pmatrix} A_{t-1} \\ p_{t-1} \\ M_{t-1} \\ I_{t-1} \end{pmatrix} + \dots + C^P \begin{pmatrix} A_{t-P} \\ p_{t-P} \\ M_{t-P} \\ I_{t-P} \end{pmatrix} + \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \mu_{3t} \\ \mu_{4t} \end{pmatrix}$$

Esta especificación está basada en el supuesto de que las variables antes descritas son variables estacionarias. Para validar este supuesto se presenta la tabla a continuacion la cual presenta los resultados de los contrastes de Dickey-Fuller

5.4 Contraste Dickey-Fuller

El contraste Dickey-Fuller es comúnmente aplicado en econometría para comprobar la presencia de tendencia sobre las series temporales. La particularidad del contraste Dickey-Fuller es que es la herramienta más fácil de usar comparado con otros contrastes más complejos que también prueban la presencia de

Representacion de las Series




Figure 5: Mi Figura

tendencia en los datos.

5.5 Contraste Dickey-Fuller Aumentada(ADF)

En estadística y econometría , una prueba de Dickey-Fuller aumentada (ADF) prueba la hipótesis nula de que una raíz unitaria está presente en una muestra de series de tiempo . La hipótesis alternativa es diferente según la versión de la prueba que se utilice, pero suele ser estacionariedad o tendencia-estacionaria . Es una versión aumentada de la prueba Dickey-Fuller para un conjunto más grande y complicado de modelos de series de tiempo.

$$H_0 : \text{La serie no es estacionaria. Si } P > 0.05$$

$$H_1 : \text{La serie es estacionaria. Si } P < 0.05$$

Para no extender mucho el analisis de los datos en R podemos resumir los resultados de la tabla 1 di-

| Análisis de Estacionaridad de la serie de Datos Mesules | | |
|---|--------------|----------------|
| variables a analizar | Probabilidad | Estacionaridad |
| A | 0.01 | si |
| P | 0.012 | si |
| M | 0.01 | si |
| I | 0.01 | si |

Figure 6: Mi Figura

ciendo que despues de haber aplicado logaritmos y diferenciado una vez cada serie se rechaza la hipotesis nula de que las series no son estacionarias esto debido a que el termino Prob que hace ´ referencia al p valor observado es menor a 0.05. Por tanto concluimos que las series son estacionarias.

Para observar las variables graficamente se presenta la figura 3 en la cual observamos que las series presentan media y variabilidad constante a lo largo del tiempo.




Figure 7: Mi Figura

5.6 Determinacion del número máximo de retardos:

Para evitar errores a la hora de elegir los retardos, usaremos criterios de seleccion que consisten en la elección del número de retardos optimo que minimiza el valor de los criterios de informacon AIC y HQ. Estos métodos están basados en la comparación de la matriz de varianzas y covarianzas del modelo para diferentes retardos, penalizando los modelos que tienen mas variables explicativas. Los criterios son los siguientes:

$$AIC(p) = \log|\Omega_p| + \frac{2}{N}pM^2$$

$$SC(p) = \log|\Omega_p| + \frac{2\log(\log(N))}{N}pM^2$$

$$HQ(p) = \log|\Omega_p| + \frac{\log(N)}{N}pM^2$$

Donde N corresponde al numero de observaciones, Ω_p a la matriz de varianzas y covarianzas del modelo estimado con un numero p de retardos y M al numero de variables dependientes del modelo. El segundo termino de cada uno de los criterios corresponde a la penalizacion antes mencionada. AIC tiende a sobreestimar p, HQ y SC son criterios consistentes, HQ y SC funcionan mejor en muestras grandes, siendo no tan claro en muestras pequenas. El Último criterio que usaremos para optimizar el numero de retardos está basado en el Error de Prediccion Final (FPE). El orden del modelo autorregresivo sera aquel que minimiza el error cuadrático medio. Entonces, un modelo optimo es el que minimiza la siguiente ecuación:

$$FPE(p) = \log|\Omega_p| \left(\frac{N+pM+1}{N-pM-1} \right)^M$$

Este criterio funciona peor que HQ y SC en muestras grandes mientras que para muestras pequenas no está claro cuál funciona mejor.

Identificando P óptimo.

Con ayuda de la función VARselect que esta implemen- tada dentro de la librería VARS que nos devuelve criterios de informacion y error de predicción final para el aumento secuencial del orden del retardo. Observando los datos que se presentan en el cuadro II, notamos que no hay armonía entre los diferentes criterios acerca de cual es el número de retardos optimo. Podemos apreciar que no hay una ´ unica solución en la eleccion del número de retardos optimo. Los contrastes basados en los criterios AIC, HQ y FPE senalan un p óptimo de 3 retardos, mientras que el criterio SC concluye en que el numero de retardos optimo es 1. Dada la concordancia de ´ los tres primeros criterios (AIC, HQ y FPE) imponemos un numero óptimo de retardos de p = 3 para nuestro modelo VAR.

6 Estimacion consistente del modelos

La estimación consistente se hace con la ayuda de la función VAR que esta implementada dentro de la librería VARS que devuelve la estimacion de un VAR utilizando MCO por cada ecuación.

$$A_t = \sum_{i=1}^3 \beta_j A_{t-j} + \sum_{i=1}^3 \gamma_j P_{t-j} + \sum_{i=1}^3 \theta_j M_{t-j} + \sum_{i=1}^3 \alpha_j I_{t-j}$$

$$P_t = \sum_{i=1}^3 \beta_j A_{t-j} + \sum_{i=1}^3 \gamma_j P_{t-j} + \sum_{i=1}^3 \theta_j M_{t-j} + \sum_{i=1}^3 \alpha_j I_{t-j}$$

$$M_t = \sum_{i=1}^3 \beta_j A_{t-j} + \sum_{i=1}^3 \gamma_j P_{t-j} + \sum_{i=1}^3 \theta_j M_{t-j} + \sum_{i=1}^3 \alpha_j I_{t-j}$$

$$I_t = \sum_{i=1}^3 \beta_j A_{t-j} + \sum_{i=1}^3 \gamma_j P_{t-j} + \sum_{i=1}^3 \theta_j M_{t-j} + \sum_{i=1}^3 \alpha_j I_{t-j}$$

Nuesro Modelo estimado.

$$\begin{pmatrix} A_t \\ p_t \\ M_t \\ I_t \end{pmatrix} = \begin{pmatrix} -0.003 \\ -0.002 \\ -0.025 \\ 0.002 \end{pmatrix} + C^1 \begin{pmatrix} A_{t-1} \\ p_{t-1} \\ M_{t-1} \\ I_{t-1} \end{pmatrix} + + C^P \begin{pmatrix} A_{t-P} \\ p_{t-P} \\ M_{t-P} \\ I_{t-P} \end{pmatrix} + \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \mu_{3t} \\ \mu_{4t} \end{pmatrix}$$

donde la estimación consistente de cada matriz es la siguiente de las matrices.

$$C^1 = \begin{pmatrix} -0.0042 & 0.029 & 0.448 & 0.448 \\ -0.025 & 0.144 & 0.098 & -0.184 \\ -0.799 & 0.327 & -0.005 & 2.391 \\ 0.0021 & 0.003 & 0 & 0.372 \end{pmatrix}$$

$$C^2 = \begin{pmatrix} 0.025 & 0.056 & 0.009 & 0.254 \\ 0.021 & 0.226 & 0.077 & 0.053 \\ -0.799 & 0. - 0.171 & 0.135 & -0.252 \\ 0.014 & -0.012 & 0.003 & -0.033 \end{pmatrix}$$

$$C^3 = \begin{pmatrix} 0.128 & 0.028 & -0.005 & 0.138 \\ 0.051 & 0.343 & 0.034 & 0.519 \\ 0.04 & 0. - 0.318 & 0.254 & 2.875 \\ -0.018 & 0.013 & 0.004 & 0.057 \end{pmatrix}$$

Coefficientes estimados para la ecuación antes propuesta utilizando la librería VAR en R.

6.1 Autocorrelación

La autocorrelación es un caso particular del modelo de regresión generalizado que se produce cuando las perturbaciones del modelo presentan correlaciones entre ellas y supone que la matriz de varianzas y covarianzas de las perturbaciones presentan valores distintos de cero en los elementos que están fuera de la diagonal principal.

Causas de la Autocorrelación.

Regularmente la autocorrelación está asociada a datos de series de tiempo y sus principales causas son:

I. Errores de especificación en el modelo como la omisión de variable(s) relevante(s), existencia de relaciones dinámicas no recogidas en el modelo o formulación de una relación funcional lineal incorrecta.

II. Existencia de efectos de proximidad entre las observaciones.

III. Manipulación de la información.

Consecuencias de la Autocorrelación Serial.

i. El estimador de MCO es todavía lineal e insesgado pero no es de mínima varianza y existe otro estimador lineal más eficiente.

ii. Las varianzas y covarianzas de los estimadores MCO son sesgados.

iii. Los intervalos de confianza y los estadísticos habituales para el contraste de la hipótesis no son adecuados.

iv. El estadístico R² es sesgado.

v. Por estos motivos, el estimador de MCO deja de ser óptimo, eficiente y los contrastes usuales quedan invalidados.

vi. Es posible encontrar otro estimador y este estimador cae dentro de los estimadores de mínimos cuadrados generalizados MCG.

Formas para Detectar el Problema de Autocorrelación Serial.

Para detectar el problema de autocorrelación se pueden utilizar métodos:

i. Gráficos.

ii. Por contrastes de hipótesis.

iii. Por medio de un examen visual de las perturbaciones, lo cual permitirá conocer la presencia de la autocorrelación. Aunque es una forma subjetiva de probar la existencia de la autocorrelación, existen pruebas formales para detectarla.

7 Chequeo del modelo

Luego de identificar nuestro modelo aplicamos las pruebas de especificacion:

7.1 Condicion de Estabilidad

Si las raíces de los polinomios son menores a 1 se satisface la condicion de estabilidad, como las raíces de los polinomios característicos son menores que 1 como se observa acontinuacion. Por tanto nuestro modelo es estable como se ouede ver en el resultado de R

```
summary(Var4)
VAR Estimation Results:
=====

Endogenous variables: A, P, M, I

Deterministic variables: const

Roots of the characteristic polynomial:

0.8445 0.8445 0.6578 0.6578 0.6136 0.6136

0.4844 0.4844 0.463 0.463 0.2721 0.2721

Call: VAR(y = Datos_VAR2, p = 3)
```

7.2 Prueba de Autocorrelacion Serial en los Residuales:

H0: Los Residuales no estan correlacionados, $p > 0.05$

H1: Los Residuales sestan correlacionados, $p < 0.05$

El p valor observado fué $pvalue < 2.2e^{-16}$.
Por lo tanto los Residuales si estan correlacionados.

7.3 Prueba de Normalidad de los Residuales:

comando en R.

```
NorVar4 <- normality.test(Var4)
NorVar4$jb.mul
```

1 H_0 : $LsResidules$ se distribuyen Normal si $p > 0.05$

2 H_0 : Los Residules No se distribuyen Normal si $p > 0.05$

Observando el p de Kurtosis con valor de $p = 2.2e16^{-16}$ el Sesgo con valor de $p = 2.2e^{-16}$. Por lo tanto los residuales no se distribuyen Normal.

7.4 Prueba de Homocedasticidad de la Varianza de los Residuales:

En estadística se dice que un modelo predictivo presenta homocedasticidad cuando la varianza del error condicional a las variables explicativas es constante a lo largo de las observaciones. Un modelo estadístico relaciona el valor de una variable a predecir con el de otras.

1 H_0 : La Varianza de los residuales es constante, si $P > 0.05$

2 H_1 : La Varianza de los residuales no es constante, si $p < 0.05$

El p-value = 0,004847 significa que la varianza de los residuales no es constante.

8 Contraste de la Causalidad de Granger:

Segun las pruebas de causalidad de Granger en R los resultados muestran que:

Causalidad de Granger con el siguiente código a continuación. Aplicando Los tests de Causalidad de Granger concluimos que:

```
grangertest(M A, order = 4)
```

```
grangertest(A M, order = 1)
```

```
grangertest(P M, order = 1)
```

```
grangertest(A I, order = 1)
```

```
grangertest(P I, order = 5)
```

```
grangertest(M I, order = 1)
```

```
grangertest(A P, order = 1)
```

```
grangertest(M P, order = 3)
```

Comando en R para obtener las graficas de las funciones de impulso.

```
impulso <- irf(Var4)
```

```
impulso
```

```
plot(impulso)
```


Analisis segun los resultdos de R.

1 La TPM sí causa en el sentido de Granger a la TIA.

2 La TPM sí causa en el sentido de Granger a la TIP.

3 El IPC sí causa en el sentido de Granger a la TPM.

4 El IPC sí causa en el sentido de Granger a la TIA.

5 El IPC sí causa en el sentido de Granger a la TIP.

6 La TIA sí causa en el sentido de Granger a la TPM.

7 La TIP sí causa en el sentido de Granger a la TPM.

8 La TIP sí causa en el sentido de Granger a la TIA.

8.1 Funciones Impulso-Respuesta:

Esta sección analiza las propiedades dinámicas del modelo estimado VAR con el apoyo de las funciones de impulso-respuesta. Seguidamente se presenta los resultados de estas funciones para el estudio.

Una función de impulso-respuesta traza la respuesta de las variables endógenas ante un shock de una desviación estándar en una de las variables del sistema. Este shock tiene la medida de una desviación estándar, lo que permite que se analice como un shock representativo de cualquier otro shock típico en un periodo cualquiera de la muestra.

El impulso-respuesta ofrece una mirada interior en la reacción de las variables macroeconómicas ante un cambio inesperado en una variable, que para el caso de la presente investigación es la inversión pública. Este shock es transmitido a todas las variables endógenas a través de la estructura dinámica del VAR (a través de los rezagos). De esta manera, la función de impulso-respuesta muestra la interacción entre la secuencia de variables endógenas, en el tiempo presente y los periodos futuros.

En esta sección se presenta las funciones de impulso respuesta para ser el analisis de las graficas.

8.2 Analisis e Interpretación de las graficas.

En esta seccion se presenta un análisis de las funciones impulso respuesta dónde:

En la figura 8 se observa que:

La TIA experimenta un aumento del 0.0013% para luego estabilizarse en torno al 0.001%

Mientras que la TIP experimenta un aumento del 0.004% para luego estabilizarse en torno al 0.002 %.

Por el contrario el IPC no experimenta cambios significativos. La figura 11 nos muestra que:

La TIA experimenta un aumento del 0.0014% para luego estabilizarse en torno al 0.001 %.




Figure 8: Respuestas de las variables ante un Impulso de la Tasa Activa (A).




Figure 9: Respuestas de las variables ante un Impulso de la Tasa Pasiva (P).




Figure 10: Respuestas de las variables ante un Impulso de la Tasa Politica Monetaria (M).




Figure 11: Respuestas de las variables ante un Impulso del índice de precios del consumidor (I).

Mientras que la TIP responde de forma negativa que luego experimenta un aumento del 0.004 % para luego estabilizarse en torno al 0.001%.

Mientras que la TPM experimenta un aumento a corto plazo del 0.007%, que luego tiene una caída del 0.0006% para estabilizarse en torno al 0.001%.

9 Conclusiones y Recomendaciones

En este trabajo hemos analizado los impulsos de la TPM e IPC sobre las Tasas de Interes Pasivas y Activas. Para ello hemos desarrollado un modelo de vectores autorregresivos (VAR).

Los efectos mostrados por las funciones de Impulso Respuesta indican que un impulso en la TPM conduce a un aumento en las tasas de interés (activas y pasivas). Mientras que un impulso del IPC conduce a un aumento en la tasa de interes activa, mientras que en el caso de la tasa de un interés pasiva experimenta una leve caída que despues conduce a un aumento.

De las conclusiones obtenidas en este trabajo se sugieren que se podrían abrir lineas de investigación que ahonden en el analisis del comportamiento económico hondureño. Sugero que se podrán incorporar variables adicionales que se consideren relevantes como ser otras tasas de interes.

10 Bibliografia

1)<http://www.estadistica.mat.uson.mx/Material/seriesdetiempo.pdf>

2)<https://www.bch.hn/estadisticas-y-publicaciones-economicas/publicaciones-de-precios/indice-de-precios-al-consumidor>

3)New Introduction to Multiple Time Series Analysis - X-Files <https://www.ucm.es/data/cont/media/www/pag-41459/VAR.pdf>

4) Jose Alberto Mauricio, Introduccion al Análisis de Series Temporales,Universidad Complutense de Madrid.

5) Christopher A. Sims (1980), "Macroeconomics and Reality.Econometrica, Volume 48